

# Sustentación Metodológica

## Solución Analítica para App de Inversiones CREAN

### 1. Metodología General

#### 1.1 Enfoque de Solución

La solución implementada sigue una arquitectura analítica end-to-end basada en:

1. **Integración de fuentes SQL:** Consolidación de 7 bases de datos SQLite con información financiera y comportamental de clientes.
2. **Feature engineering orientado a negocio:** Construcción de variables derivadas que capturan capacidad financiera, propensión de inversión y experiencia previa.
3. **Modelado predictivo two-part (hurdle):**
  - Modelo de clasificación para estimar **probabilidad de adopción**.
  - Modelo de regresión condicionada para estimar **monto potencial de inversión**.
4. **Scoring de valor esperado:** Combinación de ambos modelos para priorización comercial.

#### 1.2 Pipeline de Ejecución

El pipeline implementado en src/data\_processing/ejecucion.py ejecuta 5 etapas secuenciales:

Extracción → Limpieza → Feature Engineering → Entrenamiento → Scoring

#### Características del pipeline:

- **Reproducibilidad:** Ejecución con un solo comando, sin intervención manual.
- **Trazabilidad:** Logs detallados de cada transformación aplicada.
- **Validación automática:** Verificación de cardinalidad, nulos y esquema esperado.
- **Artefactos versionables:** Modelos serializados (.pkl) y datos intermedios (.parquet).

### 2. Procesamiento de Datos

#### 2.1 Extracción de Fuentes

**Módulo:** src/data\_processing/extraction.py

Se extrajeron 7 fuentes de datos desde archivos SQLite (.db):

| Fuente | Registros | Descripción |
|--------|-----------|-------------|
|--------|-----------|-------------|

|                       |           |                                                  |
|-----------------------|-----------|--------------------------------------------------|
| clientes              | 860,231   | Información demográfica y financiera de clientes |
| crean_aho_cte         | 1,000,000 | Saldos de cuentas de ahorro y corriente          |
| crean_bolsillos       | 1,000,000 | Saldos de bolsillos (subcuentas de ahorro)       |
| crean_fiducuenta      | 1,000,000 | Saldos de cuentas fiduciarias                    |
| crean_inv_virtual_cdt | 994,177   | Saldos de inversiones virtuales y CDTs           |
| estimador_ing         | 745,792   | Estimación algorítmica de ingresos por cliente   |
| invesbot              | 1,000,000 | Saldos en servicio de inversión automatizada     |

**Total registros cargados:** 6,600,200

#### Consideraciones técnicas:

- Cada archivo .db contiene una única tabla interna.
- El nombre de la tabla interna se detecta dinámicamente mediante query a sqlite\_master.
- Todas las tablas comparten la llave de negocio numero\_id.

## 2.2 Limpieza de Datos

**Módulo:** src/data\_processing/cleaning.py

### 2.2.1 Reglas Aplicadas a clientes

#### Eliminación de duplicados:

- Se detectaron **16 registros duplicados** por numero\_id (8 IDs afectados).
- **Acción:** Se conservó la primera ocurrencia con drop\_duplicates(subset=['numero\_id'], keep='first').
- **Justificación:** Los duplicados eran copias exactas sin información adicional.

#### Imputación de ingresos mensuales (249 nulos detectados):

- **Paso 1:** Rescate desde estimador\_ing mediante LEFT JOIN por numero\_id.
  - Se imputaron **176 registros** (70.68%) con el promedio del estimador algorítmico.
  - **Justificación:** El estimador captura patrones transaccionales históricos, proxy válido

de ingreso real.

- **Paso 2:** Imputación a 0 para los 73 restantes (29.32%).
  - **Justificación:** Clientes sin historial transaccional suficiente para estimación.
  - Se creó una bandera `flag_sin_info_financiera` para preservar esta condición.

#### Imputación de variables financieras (249 nulos en cada una):

- Columnas afectadas: `total_egresos_mensuales`, `total_activos`, `total_pasivos`.
- **Acción:** Imputación a 0.
- **Justificación:** Ausencia de información implica falta de registro, no valor explícito cero.
- Se recalculó 
$$\text{total\_patrimonio} = \text{total\_activos} - \text{total\_pasivos}$$
 post-imputación.

#### Tratamiento de variables categóricas:

- `desc_tipo_de_vivienda`: Eliminada ( $> 99\%$  de nulos, no relevante para modelo).
- `desc_genero`: Imputada con categoría explícita "NO\_REGISTRADO" (93 nulos).

**Resultado final:** clientes con **0 nulos**, 860,223 filas y 10 columnas.

### 2.2.2 Reglas Aplicadas a `crean_aho_cte`

#### Descarte de registros con saldos negativos:

- Se detectaron **1,470 registros** (0.15%) con saldo negativo en productos CUENTA DE AHORRO y CUENTA DE CORRIENTE.
- **Acción:** Eliminación de estos registros.
- **Justificación de negocio:** Un cliente con saldo negativo (sobregiro) no dispone de liquidez para invertir. La app de inversiones requiere fondos disponibles positivos para apertura.

**Resultado final:** 998,530 filas (de 1,000,000 originales).

### 2.2.3 Fuentes sin Ajustes Adicionales

Las siguientes fuentes no presentaron problemas de calidad según análisis exploratorio:

- `crean_bolsillos`
- `crean_fiducuenta`
- `crean_inv_virtual_cdt`
- `estimador_ing`
- `invesbot`

#### Consideración sobre saldos en cero:

- En `crean_inv_virtual_cdt` e `invesbot` se detectaron registros con  $\text{saldo} = 0$ .
- **Decisión:** No se descartaron.
- **Justificación:** Un saldo en cero no implica ausencia de interés. Estos clientes **activaron el**

**producto** en algún momento, lo cual es señal de propensión a inversión. Se consideran clientes con experiencia previa en el producto.

## 2.3 Feature Engineering

**Módulo:** src/data\_processing/feature\_engineering.py

### 2.3.1 Estrategia de Consolidación

Se construyó un **Master Feature Store** con granularidad de cliente (1 fila por numero\_id) mediante:

1. **Entidad maestra:** Tabla clientes (860,223 filas únicas).
2. **Agregaciones por producto:** Consolidación de métricas desde tablas transaccionales.
3. **Joins secuenciales:** LEFT JOIN desde clientes hacia cada agregación.
4. **Imputación post-join:** Variables de productos no contratados se imputan a 0 (continuas) o 0 (banderas).

**Resultado:** df\_master.parquet con **860,223 filas** y **35 columnas**.

### 2.3.2 Variables Base (desde clientes)

**Financieras directas:**

- ingresos\_mensuales, total\_egresos\_mensuales, total\_activos, total\_pasivos, total\_patrimonio

**Ratios financieros derivados:**

- $\text{margen\_libre\_estimado} = \text{ingresos\_mensuales} - \text{total\_egresos\_mensuales}$ 
  - Mide holgura operativa mensual para ahorro/inversión.
- $\text{ratio\_apalancamiento} = \frac{\text{total\_pasivos}}{\text{total\_activos}+1}$ 
  - Nivel de endeudamiento relativo al activo.
- $\text{ratio\_cobertura\_egresos} = \frac{\text{total\_activos}}{\text{total\_egresos\_mensuales} \times 12 + 1}$ 
  - Años de egresos cubiertos por activos (proxy de solvencia).

**Demográficas:**

- grupo\_edad, desc\_genero, desc\_segmento

**Banderas de calidad:**

- flag\_sin\_info\_financiera: Indica clientes sin información financiera completa.

### 2.3.3 Variables Agregadas por Producto

**Liquidez (desde crean\_aho\_cte):**

- saldo\_prom\_liquidez: Saldo promedio en cuentas de ahorro/corriente.
- saldo\_max\_liquidez: Saldo máximo observado.

- cant\_cuentas\_aho: Cantidad de productos de liquidez activos.
- flag\_tiene\_aho: Bandera de posesión ( $1 =$  tiene,  $0 =$  no tiene).

#### **Bolsillos (desde crean\_bolsillos):**

- saldo\_total\_bolsillos: Saldo agregado promedio.
- cant\_bolsillos: Cantidad de bolsillos creados.
- flag\_tiene\_bolsillos: Bandera de posesión.

#### **Fiducuenta (desde crean\_fiducuenta):**

- saldo\_prom\_fiducuenta: Saldo promedio en cuenta fiduciaria.
- flag\_tiene\_fiducuenta: Bandera de posesión.

#### **Invesbot (desde invesbot):**

- saldo\_prom\_invesbot: Saldo promedio en servicio de inversión automatizada.
- flag\_tiene\_invesbot: Bandera de posesión.

#### **Inversión Virtual / CDT (desde crean\_inv\_virtual\_cdt):**

- saldo\_prom\_inv\_cdt: Saldo promedio en CDT e inversión virtual.
- saldo\_max\_inv\_cdt: Saldo máximo observado.
- flag\_tiene\_cdt: Bandera de posesión.

### **2.3.4 Features Avanzadas de Valor**

#### **Relación con productos:**

- $\text{num\_productos\_activos} = \sum \text{flag\_tiene\_}$ 
  - Proxy de vinculación comercial y cross-sell readiness.

#### **Consolidación de inversiones:**

- $\text{saldo\_total\_inversiones} = \text{saldo\_prom\_fiducuenta} + \text{saldo\_prom\_invesbot} + \text{saldo\_prom\_inv\_cdt}$ 
  - Tamaño actual de inversión consolidada.

#### **Ratios comportamentales:**

- $\text{ratio\_liquidez\_vs\_ingreso} = \frac{\text{saldo\_prom\_liquidez}}{\text{ingresos\_mensuales}+1}$ 
  - Relación entre liquidez disponible y capacidad de ingreso.
- $\text{penetracion\_bolsillos\_vs\_liquidez} = \frac{\text{saldo\_total\_bolsillos}}{\text{saldo\_prom\_liquidez}+1}$ 
  - Uso de bolsillos relativo a liquidez general.

#### **Banderas de comportamiento:**

- $\text{flag\_superavit\_operativo} = (\text{ingresos\_mensuales} > \text{total\_egresos\_mensuales} \times 1.5)$ 
  - Señal de holgura financiera alta.

- $\text{flag\_propension\_digital\_previa} = (\text{flag\_tiene\_invesbot} = 1) \vee (\text{saldo\_prom\_inv\_cdt} > 0)$ 
  - Evidencia de afinidad digital/inversión previa.

### 2.3.5 Targets de Negocio

#### Target de clasificación (adopción):

$\text{target\_adopcion} = (\text{saldo\_total\_inversiones} > 0) \text{ or } (\text{flag\_tiene\_invesbot} == 1)$

- **Definición:** Cliente que tiene al menos un producto de inversión activo (Fiducuenta, Invesbot o CDT con saldo  $> 0$ ).
- **Distribución observada:** 220,441 positivos (25.6%) vs. 639,782 negativos (74.4%).
- **Justificación:** Proxy de propensión basada en comportamiento histórico.

#### Target de regresión (monto potencial a 12 meses):

$\text{excedente\_liquidez} = \max(0, \text{saldo\_prom\_liquidez} - (\text{total\_egresos\_mensuales} * 2))$

$\text{target\_monto\_12m} = \text{saldo\_total\_inversiones} + \text{excedente\_liquidez}$

- **Definición:** Suma de inversión actual más excedente de liquidez disponible.
- **Justificación del excedente:** Se conservan 2 meses de egresos como colchón de seguridad, el resto se considera invertible.
- **Distribución:** Altamente asimétrica, con concentración en clientes de alto patrimonio.

## 3. Modelado Predictivo

### 3.1 Arquitectura Two-Part

Se implementó una arquitectura de dos etapas:

1. **Modelo de clasificación:** Estima la probabilidad de que un cliente adopte la app.
2. **Modelo de regresión:** Estima el monto potencial de inversión, condicionado a que adopte.

#### Valor esperado de negocio:

$$EV_{\text{cliente}} = P(\text{adopción}) \times E[\text{monto} \mid \text{adopción}]$$

Esta métrica permite **priorizar clientes** considerando tanto probabilidad como magnitud de inversión.

### 3.2 Modelo de Clasificación (Adopción)

## Algoritmo: LightGBM Classifier

### Configuración de hiperparámetros:

```
LGBMClassifier(  
    objective='binary',  
    n_estimators=400,  
    learning_rate=0.05,  
    num_leaves=31,  
    subsample=0.85,  
    colsample_bytree=0.85,  
    reg_alpha=0.1,  
    reg_lambda=0.1,  
    min_child_samples=30,  
    scale_pos_weight=2.9023, # Calculado dinámicamente por desbalanceo  
    random_state=42  
)
```

### Tratamiento de desbalanceo:

- Clase positiva (adopción): 25.6%
- Clase negativa (no adopción): 74.4%
- Se aplicó  $\text{scale\_pos\_weight} = \frac{1-p}{p} = 2.9023$  para balancear la función de pérdida.

### Variables utilizadas (22 features):

- Demográficas: grupo\_edad, desc\_genero, desc\_segmento
- Financieras base: ingresos\_mensuales, total\_egresos\_mensuales, total\_activos, total\_pasivos, total\_patrimonio, flag\_sin\_info\_financiera
- Ratios: margen\_libre\_estimado, ratio\_apalancamiento, ratio\_cobertura\_egresos, ratio\_liquidez\_vs\_ingreso, penetracion\_bolsillos\_vs\_liquidez
- Banderas de comportamiento: flag\_superavit\_operativo, flag\_tiene\_aho, flag\_tiene\_bolsillos
- Magnitudes por producto: saldo\_prom\_liquidez, saldo\_max\_liquidez, cant\_cuentas\_aho, saldo\_total\_bolsillos, cant\_bolsillos

### Exclusiones intencionales para evitar data leakage:

- flag\_tiene\_fiducuenta, flag\_tiene\_invesbot, flag\_tiene\_cdt: Componentes directos del target.
- num\_productos\_activos, flag\_propension\_digital\_previa: Derivadas de banderas excluidas.

### Métricas de evaluación (test set):

- **ROC-AUC:**  $0.9100$  (excelente capacidad de discriminación)
- **PR-AUC:**  $0.8107$  (buen desempeño en clase minoritaria)
- **F1-Score:**  $0.7376$  (balance entre precisión y recall)
- **Brier Score:**  $0.1124$  (buena calibración de probabilidades)

### 3.3 Modelo de Regresión (Monto Potencial)

**Algoritmo:** LightGBM Regressor

**Configuración de hiperparámetros:**

```
LGBMRegressor(
    objective='regression',
    n_estimators=500,
    learning_rate=0.05,
    num_leaves=31,
    subsample=0.85,
    colsample_bytree=0.85,
    reg_alpha=0.1,
    reg_lambda=0.1,
    min_child_samples=30,
    random_state=42
)
```

**Transformación del target:**

- Se aplicó la transformación  $\log(1 + \text{target\_monto\_12m})$  para estabilizar la varianza.
- Los valores negativos se truncan a  $0$  en la predicción final.

**Variables utilizadas (27 features):**

- Todas las del modelo de clasificación (22).
- Adicionales: flag\_tiene\_fiducuenta, flag\_tiene\_invesbot, flag\_tiene\_cdt, num\_productos\_activos, flag\_propension\_digital\_previa.
- **Justificación:** Para el monto, la experiencia previa en inversión es predictiva (no hay leakage).

**Universo de entrenamiento:**

- Se entrena **solo sobre clientes con adopción = 1** (220,441 observaciones).
- **Justificación:** El monto solo es relevante para quienes adoptan (modelo condicionado).

### Métricas de evaluación (test set, solo adoptantes):

- **MAE:** \$16,534,419 (error absoluto medio)
- **RMSE:** \$64,475,596 (penaliza outliers)
- $R^2$  : 0.3329 (33.29% de varianza explicada)

Interpretación del  $R^2$  : Un  $R^2$  de 0.33 es aceptable en este contexto debido a:

- Alta heterogeneidad en comportamiento de inversión.
- Influencia de factores externos no observados (timing de mercado, eventos personales).
- Distribución altamente asimétrica del target.

## 3.4 Reentrenamiento Final y Scoring Productivo

### Estrategia de producción:

1. Los modelos de evaluación se entrenaron con split 80/20 para validar métricas.
2. Post-validación, se **reentrenaron ambos modelos** sobre el 100% del universo disponible.
3. Los modelos finales se serializaron en models/lgbm\_adopcion.pkl y models/lgbm\_monto.pkl.

### Generación de scores:

- Se aplicó inferencia sobre los 860,223 clientes.
- Se calculó el valor esperado:  $EV = P(\text{adopción}) \times \text{monto}_{\text{predicho}}$ .
- Se asignaron **deciles de priorización** basados en  $EV$  descendente.

### Distribución de valor esperado por decil:

| Decil | Clientes | EV Promedio  | EV Total          |
|-------|----------|--------------|-------------------|
| 10    | 86,023   | \$37,393,322 | \$3,216,685,734,1 |
| 9     | 86,022   | \$4,753,566  | \$408,911,256,320 |
| 8     | 86,022   | \$839,569    | \$72,221,384,534  |
| ...   | ...      | ...          | ...               |
| 1     | 86,023   | \$779        | \$66,988,514      |

**Salida:** data/scores/df\_predictions.parquet con columnas:

- numero\_id, proba\_adopcion, monto\_predicho\_12m, valor\_esperado, decil\_priorizacion

## 4. Hallazgos Principales

### 4.1 Hallazgos de Calidad de Datos

1. **Alta cobertura de clientes en productos:**
  - 92% de clientes tienen al menos un producto de ahorro/corriente.
  - 45% tienen productos de inversión (Fiducuenta, Invesbot, CDT).
  - **Implicación:** Base madura con experiencia en productos bancarios.
2. **Baja incidencia de datos faltantes:**
  - Solo 249 clientes (0.03%) con información financiera incompleta.
  - **Implicación:** Alta calidad en sistemas de origen.
3. **Salos negativos marginales:**
  - Solo 0.15% de registros con sobregiro en cuentas de ahorro/corriente.
  - **Implicación:** Disciplina financiera en la base de clientes.

### 4.2 Hallazgos de Segmentación

1. **Concentración de valor extrema:**
  - El 10% de clientes (Decil 10) concentra el **86.5%** del valor esperado.
  - **Implicación:** Estrategia de lanzamiento debe priorizar este segmento.
2. **Segmentación demográfica clara:**
  - Decil 10: 80% Preferente/Empresarial, 65% entre 35-54 años, 58% masculino.
  - **Implicación:** Perfil definido permite personalización de propuesta de valor.
3. **Propensión digital alta:**
  - 95% de Decil 10 usa productos digitales (Invesbot o Inversión Virtual).
  - **Implicación:** Canal app es adecuado para este segmento.

### 4.3 Hallazgos de Capacidad Financiera

1. **Superávit operativo mayoritario:**
  - 78% de clientes en Decil 10 tienen **ingresos  $>$   $1.5 \times$  egresos**.
  - **Implicación:** Alta capacidad de ahorro/inversión.
2. **Excedente de liquidez significativo:**
  - Promedio de **\$8.5M** en excedente de liquidez (Top 3 deciles).
  - **Implicación:** Capital disponible para inversión sin afectar operación.
3. **Patrimonio sólido:**
  - Patrimonio promedio  **$>$  \$500M** en Decil 10.
  - **Implicación:** Clientes con respaldo patrimonial significativo.

## 5. Conclusiones Metodológicas

### 1. Solución end-to-end exitosa:

- Se logró construir un pipeline reproducible desde datos crudos hasta scoring productivo.
- Métricas de clasificación excelentes (ROC-AUC <sup>0.91</sup>) validan la calidad del modelo.

### 2. Valor de negocio cuantificado:

- El scoring permite priorizar clientes por valor esperado, maximizando el ROI de campañas.
- La concentración de valor en Decil 10 ( <sup>86.5%</sup> ) valida la estrategia de lanzamiento selectivo.

### 3. Limitaciones reconocidas y mitigadas:

- Se documentaron supuestos explícitos y limitaciones técnicas.
- Se proponen mejoras incrementales basadas en aprendizaje continuo.

### 4. Preparación para producción:

- Modelos serializados, artefactos versionables y dashboard funcional.
- Solución lista para integración en el flujo operativo de CREAN.

**Documento generado con ayuda de IA:** 2026-08-08

**Responsable:** LDC Analítica CREAN - danaleri