


Modelo Operacional y Arquitectura de Integración CREAN

Solución Analítica para App de Inversiones

1. Modelo Conceptual de la Solución


1.1 Visión General

La solución analítica para la App de Inversiones CREAN opera como un **motor de inteligencia comercial** que alimenta decisiones de negocio en múltiples procesos del ecosistema CREAN. Su función principal es **identificar, cuantificar y priorizar** oportunidades de adopción del nuevo producto.



2. Arquitectura de Flujo de Datos

2.1 Diagrama de Arquitectura End-to-End



2.2 Flujo de Información Detallado

Etapas 1: Extracción de Fuentes

Responsable: Pipeline automatizado (extraction.py)

Inputs:

- 7 bases de datos SQLite (.db) desde sistemas de origen
- Frecuencia: Mensual (actualización programada)

Proceso:

1. Conexión a cada archivo .db
2. Detección dinámica de tabla interna
3. Carga completa a DataFrames en memoria
4. Validación de esquema esperado (columnas requeridas)

Outputs:

- Diccionario de DataFrames en memoria (6.6M registros agregados)

Validación de calidad:

- Columna numero_id presente en todas las tablas
- Cantidad de registros esperada ($\approx 1M$ por tabla transaccional)
- Tipos de datos consistentes

Etapla 2: Limpieza de Datos

Responsable: Pipeline automatizado (cleaning.py)

Inputs:

- DataFrames crudos desde Etapa 1

Proceso:

1. Eliminación de duplicados exactos en clientes (8 filas)
2. Imputación de ingresos desde estimador_ing (176 rescatados)
3. Imputación residual a 0 con bandera flag_sin_info_financiera
4. Recalculo de $\text{total_patrimonio} = \text{activos} - \text{pasivos}$
5. Descarte de registros con saldos negativos en cuentas de ahorro/corriente (1,470 filas)
6. Imputación categórica (desc_genero $\rightarrow$ "NO_REGISTRADO")

Outputs:

- Diccionario de DataFrames limpios (6.6M registros, 0 nulos)

Validación de calidad:

- Total de nulos = 0 en todas las tablas
- Cardinalidad de clientes = 860,223 (consistente)
- Salos negativos = 0 en productos críticos

Etapla 3: Feature Engineering

Responsable: Pipeline automatizado (feature_engineering.py)

Inputs:

- DataFrames limpios desde Etapa 2

Proceso:

1. Agregación de métricas por producto (saldo promedio, máximo, cantidad)
2. Construcción de ratios financieros (apalancamiento, cobertura, liquidez)
3. Generación de banderas comportamentales (superávit, propensión digital)

4. Consolidación mediante LEFT JOIN desde clientes
5. Imputación post-join (productos no contratados $\rightarrow 0$)
6. Cálculo de targets de negocio (target_adopcion, target_monto_12m)

Outputs:

- Master Feature Store: df_master.parquet (860,223 filas $\times$ 35 columnas)

Validación de calidad:

- Cardinalidad $= 860,223$ (1 fila por cliente)
- Total de nulos $= 0$
- Esquema completo con 35 columnas esperadas

Etapla 4: Entrenamiento de Modelos

Responsable: Pipeline automatizado (train.py)

Inputs:

- Master Feature Store (df_master.parquet)

Proceso:

1. Split train/test (80/20) para evaluación
2. Entrenamiento de clasificador LightGBM (adopción)
3. Entrenamiento de regresor LightGBM condicionado (monto)
4. Evaluación de métricas (ROC-AUC, MAE, RMSE, R^2)
5. Reentrenamiento sobre 100% del universo para producción
6. Serialización de modelos finales (.pkl)

Outputs:

- models/lgbm_adopcion.pkl
- models/lgbm_monto.pkl
- Métricas de evaluación (logs)

Validación de calidad:

- ROC-AUC test ≥ 0.85 (obtenido: 0.91)
- R^2 test ≥ 0.25 (obtenido: 0.33)
- Consistencia train-test (no overfitting)

Etapla 5: Scoring Productivo

Responsable: Pipeline automatizado (train.py)

Inputs:

- Modelos finales reentrenados
- Master Feature Store completo

Proceso:

1. Inferencia de probabilidad de adopción (clasificador)
2. Inferencia de monto potencial (regresor)
3. Cálculo de valor esperado: $EV = proba \times monto$
4. Asignación de deciles de priorización (basados en EV)
5. Generación de dataset de predicciones

Outputs:

- data/scores/df_predictions.parquet (860,223 filas)
 - Columnas: numero_id, proba_adopcion, monto_predicho_12m, valor_esperado, decil_priorizacion

Validación de calidad:

- Probabilidades en rango $[0, 1]$
- Montos predichos ≥ 0
- Deciles balanceados ($\approx 86,022$ clientes por decil)

2.3 Frecuencia de Actualización Recomendada

Componente	Frecuencia	Justificación
Extracción de datos	Mensual	Datos financieros actualizados mensualmente
Limpieza y Feature Eng.	Mensual	Sincronizado con extracción
Reentrenamiento de modelos	Trimestral	Balance entre drift y estabilidad
Scoring productivo	Mensual	Priorización actualizada para campañas
Dashboard	Tiempo real	Lectura desde df_predictions.parquet

3. Integración con Procesos CREAM

3.1 Mapa de Procesos y Puntos de Integración

PROCESOS CREAM	
----------------	--

1. AFILIAR / DESAFILIAR AL SERVICIO	
✓ Integración: API de Scoring	
✓ Consumo: Priorización de outreach para afiliación	
✓ Decisión: ¿A qué clientes contactar primero?	
→ Deciles 10-9: Contacto ejecutivo personalizado	
→ Deciles 8-7: Campaña digital segmentada	
→ Deciles ≤6: Campaña masiva de bajo costo	
✓ Feedback loop: Capturar tasa de conversión real por decil	

2. GESTIONAR EL USO DEL SERVICIO	
✓ Integración: Enriquecimiento de perfil de cliente	
✓ Consumo: Personalización de recomendaciones in-app	
✓ Decisión: ¿Qué productos de inversión recomendar?	
→ Decil 10: Portafolios agresivos de alto rendimiento	
→ Deciles 8-9: Portafolios balanceados	
→ Deciles ≤7: Portafolios conservadores / educativos	
✓ Feedback loop: Capturar preferencias reales de producto	

3. GESTIONAR INGRESOS Y GASTOS

- ✓ Integración: Proyección de ingresos por comisiones
- ✓ Consumo: Dimensionamiento de revenue esperado
- ✓ Decisión: ¿Cuál es el ingreso esperado por segmento?
 - Comisión promedio = 0.8% anual sobre AUM
 - Ingreso esperado Decil 10 = \$25.7B anuales
 - Total proyectado = \$29.7B anuales
- ✓ Feedback loop: Ajustar proyecciones con AUM real

4. ADMINISTRAR INFORMACIÓN

- ✓ Integración: Alimentación de Data Warehouse
- ✓ Consumo: Enriquecimiento de perfil 360 del cliente
- ✓ Decisión: ¿Qué información adicional capturar?
 - Captura de perfil de riesgo en onboarding
 - Tracking de interacciones con contenido educativo
 - Logging de decisiones de inversión
- ✓ Feedback loop: Alimentar modelos futuros con nueva info

5. MONITOREAR EL SERVICIO

- ✓ Integración: Dashboard ejecutivo (Streamlit)
- ✓ Consumo: KPIs de adopción, AUM y conversión
- ✓ Decisión: ¿El servicio está cumpliendo expectativas?
 - Monitoreo de tasa de conversión real vs. predicha
 - Alertas de drift en modelo (precisión < threshold)
 - Tracking de NPS y satisfacción por segmento
- ✓ Feedback loop: Trigger de reentrenamiento si drift > 10%

6. ADMINISTRAR EL SERVICIO

- ✓ Integración: API de requerimientos y parámetros
- ✓ Consumo: Configuración de reglas de negocio
- ✓ Decisión: ¿Qué parámetros operativos ajustar?
 - Threshold de scoring para outreach automático
 - Monto mínimo de inversión por segmento
 - Configuración de comisiones diferenciadas
- ✓ Feedback loop: Ajuste de parámetros basado en resultados

7. CONCILIAR TRANSACCIONES Y CONTABILIDAD

- ✓ Integración: Trazabilidad de origen de cliente
- ✓ Consumo: Atribución de revenue a campaña de origen
- ✓ Decisión: ¿Qué canal/campaña generó más valor?
 - Atribución de AUM a decil de origen
 - ROI por segmento de priorización
 - Coste de adquisición (CAC) por decil
- ✓ Feedback loop: Optimizar asignación de presupuesto

3.2 Puntos de Decisión Críticos

Decisión 1: ¿A quién contactar primero?

Pregunta de negocio: ¿En qué orden priorizar el outreach comercial?

Input de la solución:

- decil_priorizacion (1-10)
- valor_esperado por cliente

Regla de decisión:

if decil_priorizacion in (10, 9):

Contacto ejecutivo personalizado (costo alto, conversión alta)

elif decil_priorizacion in (8, 7):

Campaña digital segmentada (costo medio, conversión media)

else:

Campaña masiva genérica (costo bajo, conversión baja)

Medición de éxito:

- Tasa de conversión real $\geq$ en Decil 10
- $$\text{ROI de campaña} = \frac{\text{Revenue generado} - \text{Costo campaña}}{\text{Costo campaña}}$$

Decisión 2: ¿Qué producto recomendar a cada cliente?

Pregunta de negocio: ¿Cómo personalizar la oferta de inversión?

Input de la solución:

- proba_adopcion (proxy de sofisticación financiera)
- monto_predicho_12m (capacidad de inversión)
- Features de perfil: total_patrimonio, margen_libre_estimado, flag_propension_digital_previa

Regla de decisión:

if proba_adopcion > 0.8 and monto_predicho_12m > 50000000:

Portafolio agresivo (acciones, fondos alternativos)

elif proba_adopcion > 0.5 and monto_predicho_12m > 10000000:

Portafolio balanceado (mixto renta fija/variable)

else:

Portafolio conservador (CDT digital, fondos de liquidez)

Medición de éxito:

- % de clientes que completan inversión después de recomendación
- Tasa de retiro anticipado (churn) por tipo de portafolio

Decisión 3: ¿Cuándo reentrenar los modelos?

Pregunta de negocio: ¿El modelo sigue siendo preciso o hay drift?

Input de la solución:

- Tasa de conversión real vs. predicha (por decil, por mes)
- Métricas de error: MAE, RMSE en ventana móvil de 3 meses

Regla de decisión:

```

ratio_conversion = tasa_conversion_real / tasa_conversion_predicha
if ratio_conversion < 0.85 or ratio_conversion > 1.15:
    # ALERTA: Drift detectado -> Acción: Reentrenamiento urgente
elif dias_desde_ultimo_entrenamiento > 90:
    # Reentrenamiento programado


```

Medición de éxito:

- Drift $<$ en ventana de 3 meses
- ROC-AUC post-reentrenamiento $\geq$ ROC-AUC baseline

4. Esquema de Operación MLOps

4.1 Ciclo de Vida del Modelo en Producción



5. Métricas de Éxito Operacional

5.1 Indicadores Técnicos (MLOps)

Métrica	Target	Frecuencia de Medición
Uptime del pipeline	$\geq$	Diaria
Latencia de scoring	$<$ segundos por cliente	Por ejecución
Drift de modelo (AUC)	$<$ vs. baseline	Mensual
Calidad de datos (nulos)	0 nulos post-limpieza	Por ejecución
Tiempo de ejecución pipeline	$<$ minutos	Por ejecución

5.2 Indicadores de Negocio (Alineados con Procesos CREAN)

Proceso CREAN	Métrica de Impacto	Target	Medición
Afiliación	Tasa de conversión Decil 10	$\geq$	Mensual
Gestión de uso	% clientes activos post-adopción	$\geq$	Trimestral
Ingresos	Revenue real vs. proyectado	$\pm 15\%$	Trimestral
Monitoreo	NPS del servicio	$\geq$	Mensual
Administración	Tiempo de resolución de incidencias	$<$	Continuo

Responsable: LDC Analítica CREAN - danaleri